Softverski algoritmi u sistemima automatskog upravljanja

Online News Popularity

Marijela Veljković RA172-2022

septembar, 2025.

Cilj projekta: Na osnovu dataseta koji sadrži statističke karakteristike članaka objavljenih na Mashable u periodu od dve godine predvideti popularnost (**broj deljenja**) članaka. Dostupni atributi (ulazi) su:

- url: URL članka
- timedelta: broj dana između objave članka i prikupljanja podataka
- n_tokens_title: broj reči u naslovu
- n_tokens_content: broj reči u sadržaju
- n_unique_tokens: udeo unikatnih reči u sadržaju
- n_non_stop_words: udeo reči koje nisu stop-reči u sadržaju
- n_non_stop_unique_tokens: udeo unikatnih reči koje nisu stop-reči
- num_hrefs: broj linkova
- num_self_hrefs: broj linkova ka drugim Mashable člancima
- num_imgs: broj slika
- num_videos: broj video snimaka
- average_token_length: prosečna dužina reči u sadržaju
- num_keywords: broj ključnih reči u metapodacima
- data_channel_is_lifestyle: da li članak pripada kategoriji Lifestyle
- data_channel_is_entertainment: da li članak pripada kategoriji Entertainment
- data_channel_is_bus: da li članak pripada kategoriji Business
- data_channel_is_socmed: da li članak pripada kategoriji Social Media
- data_channel_is_tech: da li članak pripada kategoriji Tech
- data_channel_is_world: da li članak pripada kategoriji World
- kw_min_min: najmanja vrednost deljenja za najgoru ključnu reč
- kw_max_min: najveća vrednost deljenja za najgoru ključnu reč
- kw_avg_min: prosečna vrednost deljenja za najgoru ključnu reč
- kw_min_max: najmanja vrednost deljenja za najbolju ključnu reč
- kw_max_max: najveća vrednost deljenja za najbolju ključnu reč
- kw_avg_max: prosečna vrednost deljenja za najbolju ključnu reč
- kw_min_avg: najmanja vrednost deljenja za prosečnu ključnu reč
- kw_max_avg: najveća vrednost deljenja za prosečnu ključnu reč
- kw_avg_avg: prosečna vrednost deljenja za prosečnu ključnu reč
- self_reference_min_shares: minimalan broj deljenja referenciranih Mashable članaka
- self_reference_max_shares: maksimalan broj deljenja referenciranih Mashable članaka
- self_reference_avg_sharess: prosečan broj deljenja referenciranih Mashable članaka

- weekday_is_monday: da li je članak objavljen u ponedeljak
- weekday_is_tuesday: da li je članak objavljen u utorak
- weekday_is_wednesday: da li je članak objavljen u sredu
- weekday_is_thursday: da li je članak objavljen u četvrtak
- weekday_is_friday: da li je članak objavljen u petak
- weekday_is_saturday: da li je članak objavljen u subotu
- weekday_is_sunday: da li je članak objavljen u nedelju
- is_weekend: da li je članak objavljen tokom vikenda
- LDA_00: bliskost sa LDA temom 0
- LDA_01: bliskost sa LDA temom 1
- LDA_02: bliskost sa LDA temom 2
- LDA_03: bliskost sa LDA temom 3
- LDA_04: bliskost sa LDA temom 4
- global_subjectivity: subjektivnost teksta
- global_sentiment_polarity: polaritet sentimenta teksta
- global_rate_positive_words: udeo pozitivnih reči u sadržaju
- global_rate_negative_words: udeo negativnih reči u sadržaju
- rate_positive_words: udeo pozitivnih reči među nenutralnim tokenima
- rate_negative_words: udeo negativnih reči među nenutralnim tokenima
- avg_positive_polarity: prosečan polaritet pozitivnih reči
- min_positive_polarity: najmanji polaritet pozitivnih reči
- max_positive_polarity: najveći polaritet pozitivnih reči
- avg_negative_polarity: prosečan polaritet negativnih reči
- min_negative_polarity: najmanji polaritet negativnih reči
- max_negative_polarity: najveći polaritet negativnih reči
- title_subjectivity: subjektivnost naslova
- title_sentiment_polarity: polaritet naslova
- abs_title_subjectivity: apsolutni nivo subjektivnosti naslova
- abs_title_sentiment_polarity: apsolutni nivo polariteta naslova
- shares: broj deljenja na društvenim mrežama

Ovo je problem **regresije** zato što je cilj predvideti **kontinuiranu numeričku vrednost** – tačan broj deljenja (shares).

Koraci u rešavanju problema:

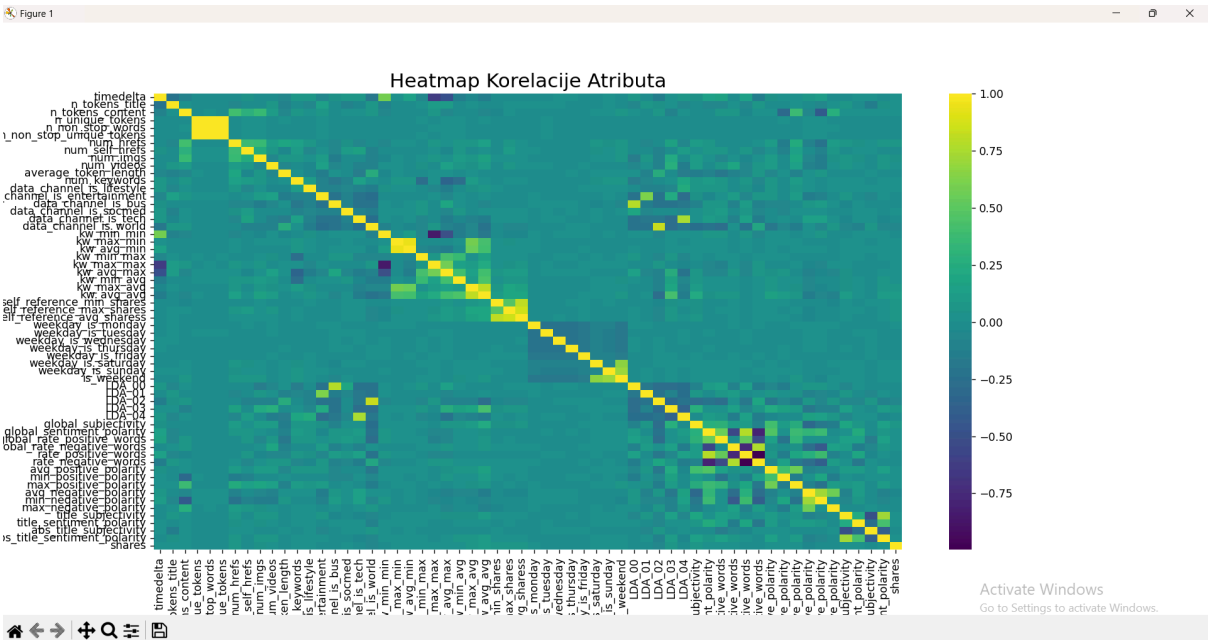
1. Učitavanje podataka

Online News Popularity dataset ima 61 kolonu i 39 644 vrsta, u početnom koraku uklonjeni su postojeći razmaci iz naziva kolona, uklonjeni su članci bez sadržaja (n_tokens_content = 0), uklonjena je kolona url, izvršena je provera da li neki podaci nedostaju i da li postoje duplikati.

url - izbačen iz dataseta jer je jedinstven. Mašinski model ne može da nauči nikakav obrazac iz podatka koji se nikada ne ponavlja. Sve potencijalno korisne informacije iz url-a (kao što su tema ili ključne reči) su već mnogo bolje predstavljene u drugim, numeričkim kolonama.

n_tokens_content - izbačen iz dataseta jer članak bez reči u svom sadržaju, po definiciji, nije članak. To su "prazni" unosi koji predstavljaju grešku u podacima, a ne validne primere iz kojih model treba da uči.

Takođe kreirala sam matricu korelacije nad celokupnim datasetom, kako bih dobila brz, vizualan i kvantitativan pregled linearnih odnosa između svih numeričkih varijabli u mom setu podataka.



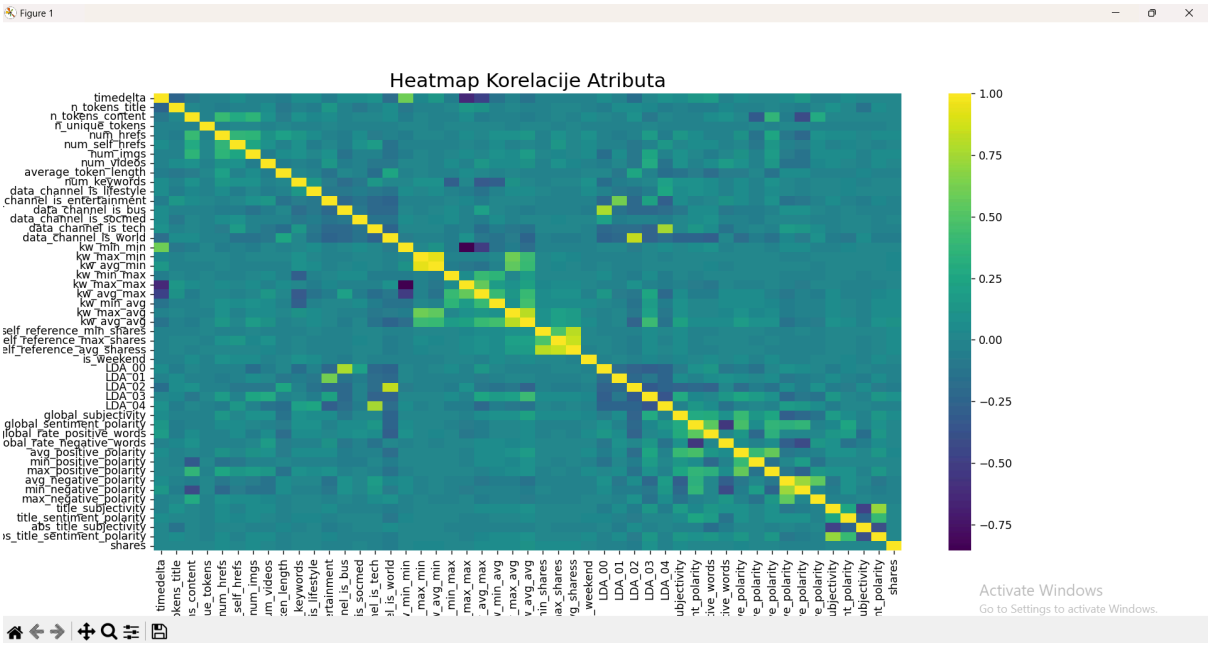
Svetlo žuta boja: Jaka pozitivna korelacija (blizu +1). Kada jedan atribut raste, i drugi raste.

Tamno ljubičasta/crna boja: Jaka negativna korelacija (blizu -1). Kada jedan atribut raste, drugi opada.

Zelena/tirkizna boja: Slaba ili nikakva korelacija (blizu 0). Atributi nisu linearno povezani.

Jasni svetli blokovi nam govore da više atributa nose istu informaciju, pa te atribute uklanjamo. Na osnovu ove slike, uklonila sam n_non_stop_words, sve pojedinačne weekday_is_... i rate_... varijante sentimenta. To bi trebalo da pojednostavii model bez gubitka važnih informacija.

Zatim sam za ažuriran dataset opet izračunala matricu korelacije kako bih zaključila koji atributi najviše utiču na izlaz.

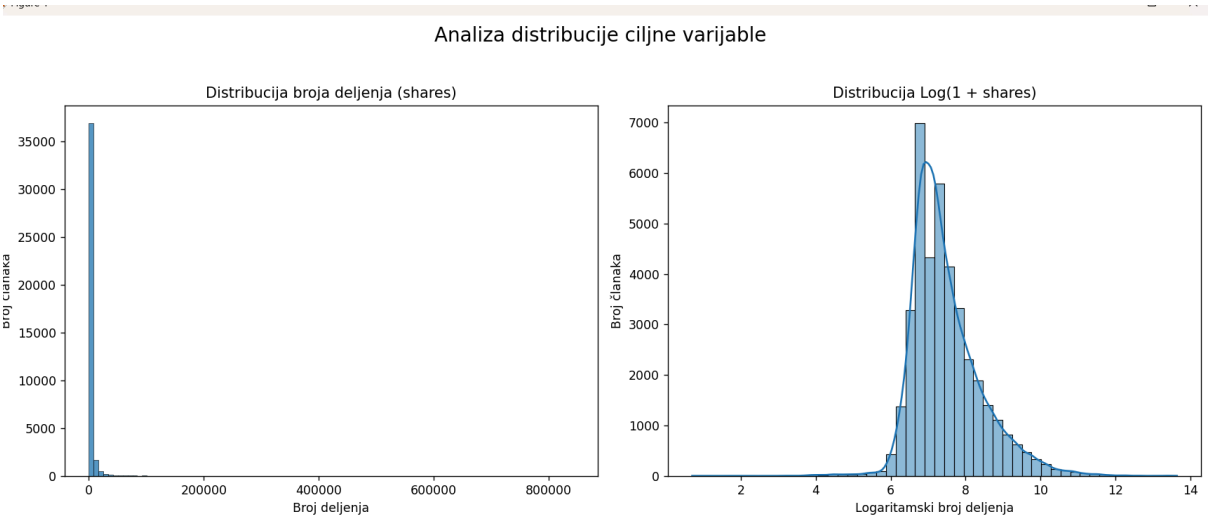


Ova matrica sadrži manje svetlih blokova što znači da je šum uspešno uklonjen, bolje su vidljive važne korelacije i veze sa shares. kw_avg_avg, self_reference_avg_sharess i drugi atributi iz kw_... i self_reference_… su najjači linearni prediktori, koji daju osnovu za kriranje nelinearnih odnosa.

2. Ispitivanje metrika na modelima Linear Regression, Ridge, Lasso

Početni korak je učitavanje ažuriranog dataseta, a zatim i kreiranje feature engineering-a, na osnovu matrice korelacije i najvažnijih atributa. Feature engineering podrazumeva stvaranje nelinearnih veza i interakcija između atributa kako bi ih model bolje naučio i dao bolju predikciju.

Zatim sam uradila logaritamsku transformaciju ciljne varijable (y_log = np.log1p(y)). To sam uradila da bi linearni modeli mogli da daju smislene rezultate za ovaj dataset koji ima ekstremnu distribuciju.



Ciljna varijabla shares je izrazito asimetrična. Većina vrednosti je zbijena na početku, sa dugačkim "repom" ekstremnih vrednosti. Log-transformacija pretvara asimetričnu distribuciju u nešto što mnogo više liči na normalnu distribuciju, čineći je pogodnijom za linearne modele, takođe i "pripitomljava" ove ekstremne vrednosti, smanjuje njihov uticaj i omogućava modelu da se fokusira na učenje opštih obrazaca iz većine podataka. To jest model se trenira u pogodnoj sredini, koja je sređenija od realne, on daje predikcije u “svetu” u kome je učen.

Kao rezultat prikazujem i logaritamsku i realnu skalu da bi metrike imale realno značenje i da bi rezultati bili razumljivi i upotrebljivi za donošenje odluka. Iako logaritamska skala ima bolje rezultate za nas je to nebitno, pravi rezultati za nas su oni na realnoj skali.

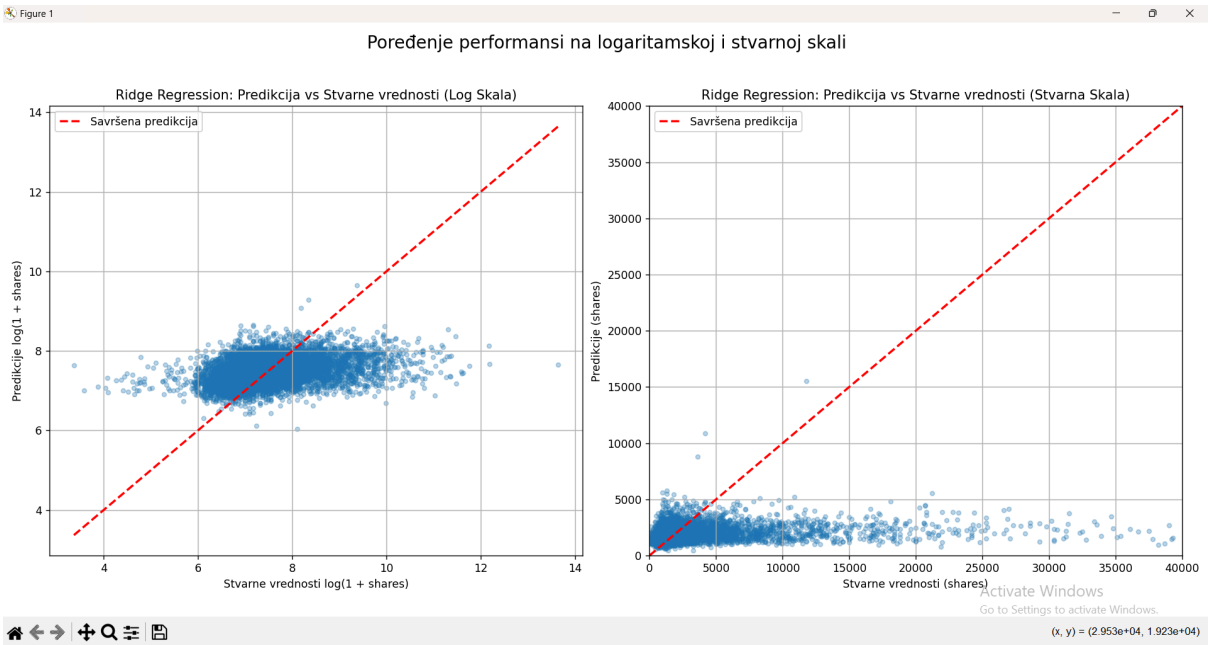
Takođe sam uvela i StandardScaler() koji od atributa oduzima originalne, proizvoljne jedinice mere i stavlja ih na zajedničku, standardizovanu skalu, omogućavajući modelu da donosi odluke zasnovane na stvarnoj informaciji, a ne na veličini brojeva.

Zatim sam podelila podatke na train (80%) i test (20%) skup, definisala skup modela koji će se koristiti za treniranje i evaluaciju.

Metrike koje poredimo su sledeće:
MAE - Prosečna veličina greške u originalnim jedinicama. Ako je MAE na stvarnoj skali 2500, to ima direktno značenje da model pogreši za 2500 deljenja. Pošto ne kvadrira grešku, jedna ogromna greška na viralnom članku neće toliko povećati MAE kao što će MSE. Zbog toga, MAE daje bolju sliku o tipičnoj, svakodnevnoj grešci modela na "normalnim" člancima.

MSE - Prosek kvadrata grešaka. Penalizuje velike greške: zbog kvadriranja, velike greške postaju neproporcionalno "skuplje".

R^2 - Procenat varijanse u ciljnoj varijabli koji je model uspeo da objasni. R^2 od 0.15 govori: "Naš model je uspeo da objasni 15% ukupne varijacije u broju deljenja. Preostalih 85% je posledica faktora koje model nije uhvatio (šum, sreća, spoljni događaji)." Ovo daje realan osećaj koliko je problem uopšte rešiv sa podacima koje imamo.



Levi grafik (Log Skala): Ovde vidimo "srce" onoga što je model naučio. Plavi "oblak" tačaka jasno prati trend crvene linije (savršene predikcije). Ovo nam govori da model uspeva da nauči opšti obrazac. Međutim, oblak je veoma širok i raspršen, što

pokazuje da su predikcije daleko od savršenih i da postoji velika varijansa koju model ne može da objasni.

Desni grafik (Stvarna Skala): Ovo je "surova realnost". Ovde vidimo posledice logaritamske transformacije.

"Podna" greška: Velika većina tačaka je zbijena u donjem levom uglu. Za članke sa manjim brojem deljenja, model je relativno blizu.

Sistematsko podcenjivanje : Skoro sve tačke se nalaze ispod crvene linije. Model je previše konzervativan. On uspeva da predvidi da će članak biti popularan, ali se "ne usuđuje" da predvidi ekstremno visoke vrednosti. Zato predviđa npr. 10,000, kada je stvarna vrednost 30,000.

```
--- Rezultati za: Linear Regression ---
  Na LOGARITAMSKOJ skali:
    MAE: 0.6427, MSE: 0.7471, R²: 0.1258
  Na STVARNOJ skali:
    MAE: 2318.06, MSE: 144604848.78, R²: -0.0055

--- Rezultati za: Ridge Regression ---
  Na LOGARITAMSKOJ skali:
    MAE: 0.6427, MSE: 0.7472, R²: 0.1257
  Na STVARNOJ skali:
    MAE: 2318.18, MSE: 144604400.92, R²: -0.0055

--- Rezultati za: Lasso Regression ---
  Na LOGARITAMSKOJ skali:
    MAE: 0.6458, MSE: 0.7524, R²: 0.1197
  Na STVARNOJ skali:
    MAE: 2320.54, MSE: 144867347.69, R²: -0.0073
```

$R^2 \approx -0.005$: Ovo je najvažniji rezultat, znači da je model, kada se prevede nazad na stvarnu skalu, lošiji od najprostijeg mogućeg modela (koji uvek predviđa prosečan broj deljenja). To se dešava zbog onog sistematskog podcenjivanja viralnih članaka,

kvadratna greška postaje astronomska, što uništava R^2 skor.

Linear vs. Ridge: Rezultati su skoro identični. To nam govori da overfitting nije bio veliki problem za linearnu regresiju, pa Ridge-ova regularizacija nije imala šta da "popravlja".

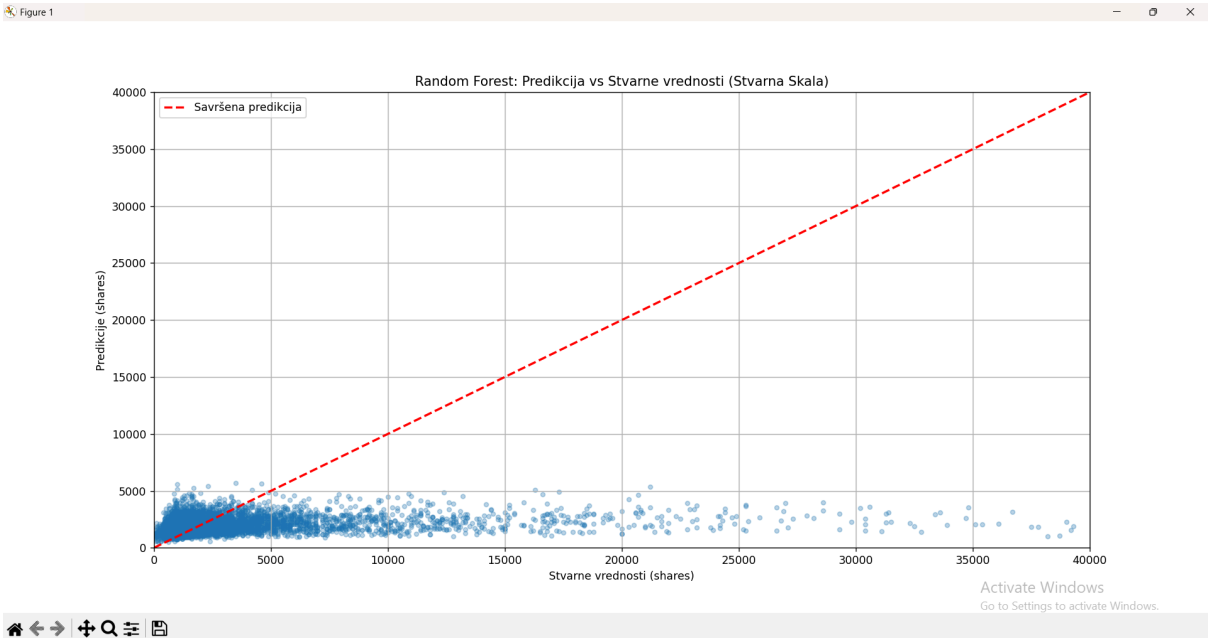
Lasso: Lasso ima blago lošije rezultate od Linearne i Ridge regresije. To znači da je Lasso, u pokušaju da pojednostavi model, verovatno postavio koeficijent nekog korisnog atributa na nulu, čime je malo pogoršao performanse.

Zaključak: Ovim su testirane granice linearnih modela, problem je jako nelinearan, negativan R^2 na stvarnoj skali je jasan dokaz da linearni modeli nisu adekvatni za ovaj problem, čak ni uz pomoć log-transformacije i pametnog inženjeringa atributa. Oni jednostavno ne mogu da uhvate kompleksnu, haotičnu prirodu viralnosti.

3. Ispitivanje metrika na modelu Random Forest

U principu, ovde je rađena ista stvar kao i kod prošlih modela, učitani su podaci, kreiran je feature engineering, ciljna varijabla je transformisana u logaritamsku skalu, i podaci su podeljeni na test i train skup, sa jednom veoma bitnom razlikom, a to je da X nije skaliran. Jer za razliku od linearnih modela (posebno Ridge i Lasso), modeli zasnovani na stablima odlučivanja (Decision Tree, Random Forest, Gradient Boosting) nisu osetljivi na skalu atributa. Razlog je što oni donose odluke na osnovu pojedinačnih pragova. Nije im važno da li je neki drugi atribut na skali od 0 do 1 ili od 0 do 100,000; odluke se donose nezavisno za svaki atribut.

Takođe, uključila sam i optimizovanje hiperparametara pomoću RandomizedSearchCV. Testiranje svih mogućih kombinacija hiperparametara (GridSearchCV) bi bilo izuzetno sporo. RandomizedSearchCV umesto toga testira nasumičan broj kombinacija (n_iter=40) iz definisanog prostora (param_dist). Ovo je mnogo brže i često daje podjednako dobre rezultate. cv=3 znači da se za svaku od 40 kombinacija sprovodi 3-struka unakrsna validacija kako bi se dobila pouzdana procena performansi. Nakon što RandomizedSearchCV završi, on automatski trenira finalni model na celom trening setu koristeći najbolju kombinaciju hiperparametara koju je pronašao. Taj model je dostupan preko atributa best_estimator_.




```
--- Započeta pretraga najboljih hiperparametara za Random Forest ---

Pretraga završena.
Najbolji pronađeni parametri:
{'n_estimators': 300, 'min_samples_split': 10, 'min_samples_leaf': 4, 'max_features': 'sqrt', 'max_depth': 30}

--- Rezultati finalnog modela (NA LOGARITAMSKOJ SKALI) ---
Srednja apsolutna greška (MAE): 0.6224
Srednja kvadratna greška (MSE): 0.7071
R² koeficijent determinacije: 0.1727

--- Rezultati finalnog modela (NA STVARNOJ SKALI) ---
Srednja apsolutna greška (MAE): 2283.73
Srednja kvadratna greška (MSE): 144113671.90
R² koeficijent determinacije: -0.0020
```

Zaključak sa grafika - model je naučio da predviđa popularnost za "prosečne" ili "ispodprosečne" članke, ali je potpuno neuspešan u identifikovanju i predviđanju viralnih članaka. On je "naučio" da je najsigurnije predvideti nisku vrednost jer je većina članaka u trening setu imala nizak broj deljenja. Zbog ogromnih, sistematskih promašaja na viralnim člancima, ukupna greška modela postaje veća od greške najprostijeg mogućeg modela, i R^2 pada u negativnu teritoriju.

Ukoliko bi uporedili Random Forest sa linearnim modelima, gledajući logaritamsku skalu koja prikazuje koliko je model dobar u matematičkom smislu (na podacima na kojima je treniran), Random Forest ima R^2 od 0.173, dok linearni model ima samo 0.126. Ovo je velika razlika. Random Forest je uspeo da objasni značajno veći deo

varijabilnosti u podacima. Uspeo je da nauči kompleksne, nelinearne odnose i interakcije između atributa koje su linearni modeli, po svojoj prirodi, potpuno ignorisali.

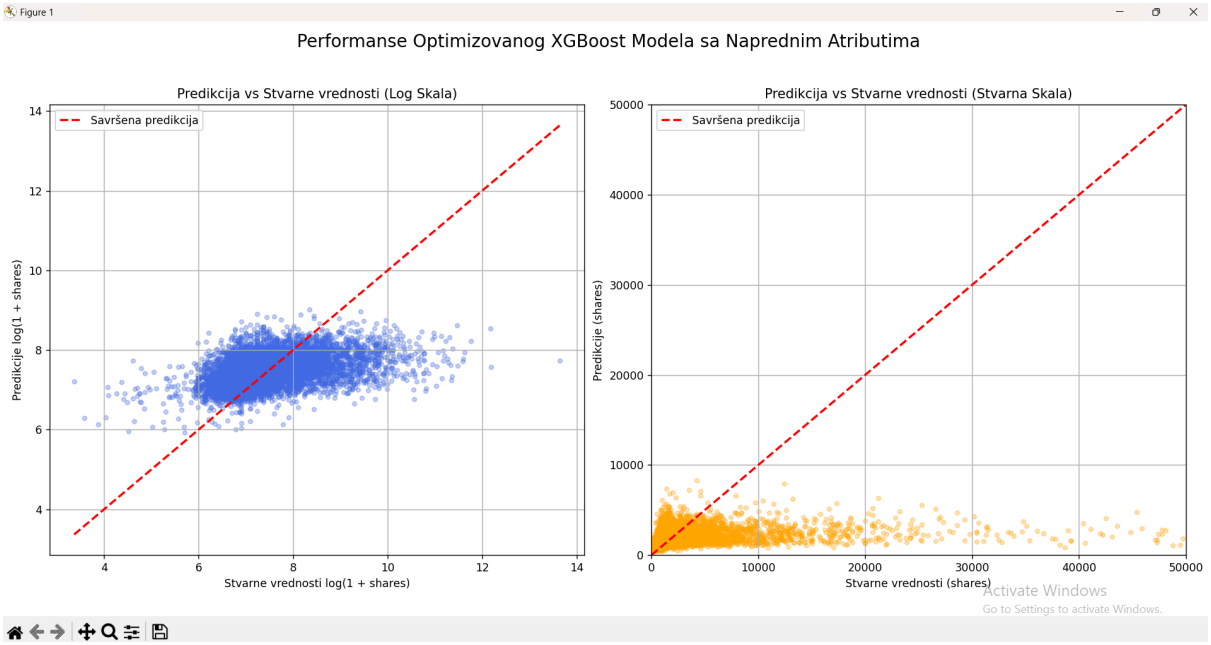
Zaključak: Random Forest model je "pametniji", ali i "plašljiviji" od linearnih modela. Pametniji je jer je uočio kompleksne obrasce (što se vidi na log skali), a plašljiviji je jer se ne usuđuje da predvidi visoke vrednosti kojih se "nagledao" u manjini tokom treninga. Predviđanje tačnog broja deljenja je ekstremno teško zbog viralnih članaka koji predstavljaju glavni problem.

4. Ispitivanje metrika na modelu Gradient Boosting

Osnovni korak u ovom pristupu je takođe učitavanje podataka, osnovni feature engineering a zatim i dodat napredni feature engineering (umesto da samo gurnemo sirove podatke u jači model, kreirala sam nove, mnogo moćnije atribute).

Radim `log1p` transformaciju koja je ključna jer "smiruje" ekstremne vrednosti `shares`, omogućavajući modelu da lakše nauči obrasce. Podela na trening/test skup osigurava da ćemo moći objektivno da ocenimo performanse modela na podacima koje nikada pre nije video.

Omogućavam automatsko testiranje 50 nasumičnih kombinacija hiperparametara (kao što su brzina učenja, dubina stabala, itd.) i pronalazenje one koja daje najbolje rezultate kroz unakrsnu validaciju. Pri čemu koristim XGBoost koji je bolji od "običnog" Gradient Boostinga jer je to ekstremno optimizovana i unapređena implementacija istog osnovnog algoritma.




```
Pretraga je završena.
Najbolji pronađeni parametri:
{'subsample': 0.9, 'n_estimators': 800, 'max_depth': 7, 'learning_rate': 0.01, 'gamma': 0, 'colsample_bytree': 1.0}

--- Rezultati finalnog modela (NA LOGARITAMSKOJ SKALI) ---
Srednja apsolutna greška (MAE): 0.6141
Koren srednje kvadratne greške (RMSE): 0.8333
R² koeficijent determinacije: 0.1875

--- Rezultati finalnog modela (NA STVARNOJ SKALI) ---
Srednja apsolutna greška (MAE): 2272.84
Koren srednje kvadratne greške (RMSE): 11990.39
R² koeficijent determinacije: 0.0003
```

Ovde je umesto metrike MSE računata RMSE koja je u istim jedinicama kao ciljna varijabla (u ovom slučaju, shares), dok je MSE u kvadratnim jedinicama (shares²).

RMSE - Uzima prosek kvadratnih grešaka, pa izvadi koren. Ukoliko je velika vrednost moze značiti da model radi dobro ali da pravi nekoliko veoma velikih grešaka.

Zaključak: Svi modeli su imali poteškoća sa predviđanjem ekstremnih vrednosti ("viralnih" članaka) na stvarnoj skali, XGBoost je jedini pokazao merljivu, iako skromnu, prednost. Njegova superiornost potiče iz kombinacije naprednog "boosting" algoritma i efikasnog korišćenja pažljivo kreiranih atributa, što mu je omogućilo da nadmaši i svog najbližeg konkurenta (Random Forest) i fundamentalno jednostavnije linearne modele. Prvi put dobijamo pozitivan R², to znači da je

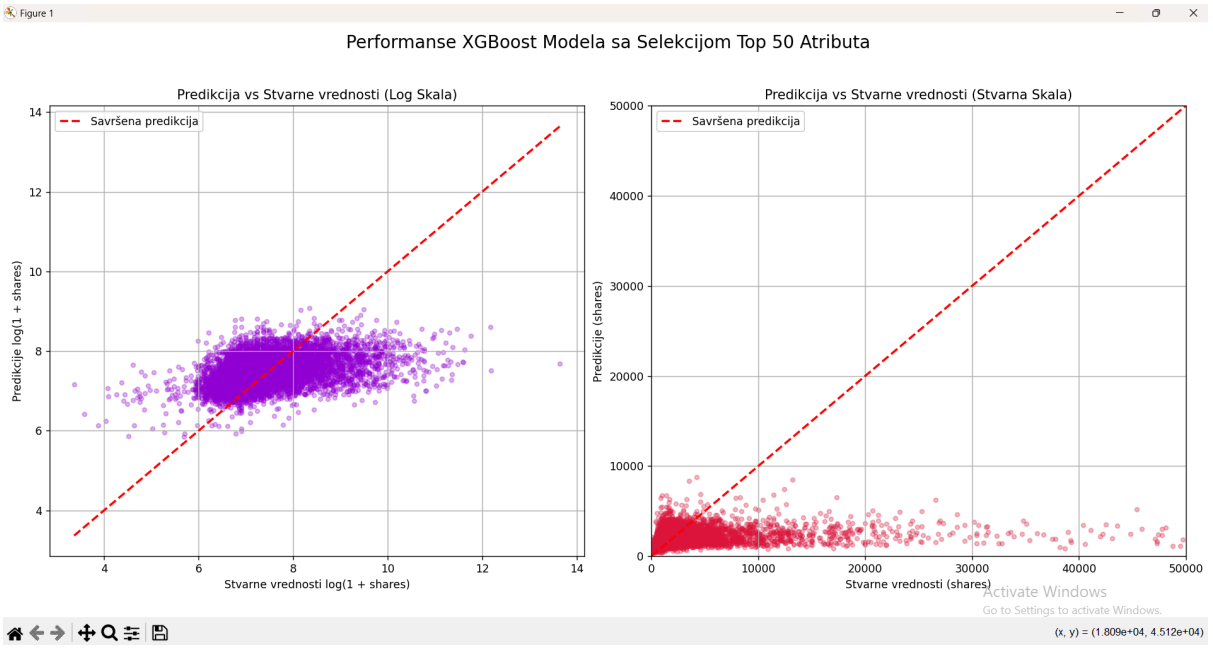
XGBoost model **po prvi put bolji od referentnog modela**. Njegove predikcije su, u proseku, bliže stvarnim vrednostima nego što je to prosečna vrednost. Model je uspeo da iskoristi atribute (karakteristike članaka) da napravi, makar i minimalno, informisanije i tačnije predikcije.

5. Ispitivanje metrika na modelu XGB sa Feature Selection

Ovim pristupom smanjujemo broj atributa, a samim tim i kompleksnost modela. Jednostavniji model ima manju šansu da se preterano prilagodi i veću šansu da dobro generalizuje svoje znanje na nove podatke.

Cela struktura koda je identična kao i do sad, s tim što je glavna razlika u selekciji. Kod sa selekcijom uvodi ceo novi blok koda čiji je jedini cilj da filtrira i smanji X pre glavnog treninga.

Poređenjem rezultata za 30, 40 i 50 selektovanih atributa najbolje metrike se dobijaju upravo za 50.



```
Pretraga je završena.
Najbolji pronađeni parametri:
{'subsample': 0.9, 'n_estimators': 800, 'max_depth': 7, 'learning_rate': 0.01, 'gamma': 0, 'colsample_bytree': 1.0}

--- Rezultati finalnog modela sa Top 50 Atributa (NA LOGARITAMSKOJ SKALI) ---
Srednja apsolutna greška (MAE): 0.6156
Koren srednje kvadratne greške (RMSE): 0.8352
R² koeficijent determinacije: 0.1839

--- Rezultati finalnog modela sa Top 50 Atributa (NA STVARNOJ SKALI) ---
Srednja apsolutna greška (MAE): 2275.72
Koren srednje kvadratne greške (RMSE): 11990.25
R² koeficijent determinacije: 0.0004
```

Performanse na stvarnoj skali su i dalje niske ali su pozitivne. Model je i dalje bolji od prostog pogađanja proseka, za razliku od Random Foresta i linearnih modela. Ovim smo testirali krajnje granice poboljsanja predviđanja.

Zaključak: Problem je u fundamentalnoj prirodi onoga što pokušavamo da predvidimo. Popularnost na internetu nije linearna i nije ravnomerno raspoređena. Ona prati takozvanu distribuciju zakona moći (Power Law Distribution). Ogromna većina članaka (recimo 95%) ima mali do umeren broj deljenja. Oni su "svakodnevni" sadržaj. Međutim, mali, sićušan procenat članaka (možda 1%) postanu "viralni hitovi" i imaju ekstremno visok broj deljenja, koji je redovima veličine veći od proseka. To predstavlja ogroman problem za naš model jer se model trenira na svih ~39,000 članaka. On nauči pravila koja važe za veliku većinu (95%) "normalnih" članaka. Zato su performanse na logaritamskoj skali relativno pristojne ($R^2 \approx 0.18$) – logaritam "sabije" te ekstremne vrednosti i dozvoljava modelu da se fokusira na većinu. Međutim, pravila koja važe za "normalne" članke ne važe za "viralne". Viralnost često zavisi od faktora koje je nemoguće izmeriti: kulturni trenutak, spominjanje od strane poznate ličnosti, neočekivani spoljni događaj, ili jednostavno "sreća". Ovom probemu doprinosi i ograničenost dataseta koji opisuje samo unutrašnje karakteristike članka: broj reči, broj slika, sentiment, ključne reči..